

Predicting F1 Pit Stops

从 2058 名到 321 名的建模之旅

Kaggle Playground Series S6E5



问题定义

预测 F1 赛车下一圈是否进站

任务类型

- 二分类 (Binary Classification)
- 评估指标: AUC-ROC

数据规模

- 训练集: 439,140 条
- 测试集: 188,165 条
- 特征数: 15 个原始字段

关键字段

字段	含义
PitNextLap	目标: 下一圈是否进站
TyreLife	当前轮胎已跑圈数
RaceProgress	比赛进度 (0~1)
Compound	轮胎类型 (Soft/Medium/Hard)
Position	当前排名

🏁 F1 进站的业务背景


比赛规则

- 跑固定圈数（50-70 圈），先跑完者赢
- 必须使用至少两种不同配方的轮胎（规则强制）
- 换胎在维修区（pit lane）完成 → 进站（pit stop）

为什么经常换 2-3 次胎？


- 软胎磨损太快，撑不到比赛结束
- 换新胎后圈速明显更快（undercut 策略）
- 安全车期间进站损失时间最少

车队的时间优化问题



🔍 数据探索：关键发现

目标分布



哪些因素影响进站?



- 🌐 轮胎寿命 — TyreLife 越大，进站概率越高
- 📉 圈速衰退 — LapTime_Delta 为正说明变慢
- 🏁 比赛进度 — 后半程进站概率升高
- 🏆 排名压力 — 前排和后排策略不同
- 🛠️ **Stint** 数 — 第几个 Stint 影响策略

- 不平衡比例 $\approx 3:1$
- 需要处理类别不平衡



建模迭代：从 2058 到 307

AUC Score by Version



阶段	模型	排名	AUC
v1	LightGBM	2058	0.94068
v2	LightGBM 优化	1975	0.94209



特征工程：从 15 到 300+

域特征

- `EstimatedTotalLaps` =
`LapNumber / RaceProgress`
- `LapsRemaining` = 总圈数 - 当前圈
- `RacePhase` (P1-P5 分段)
- `TyreAgeRatio` = 轮胎寿命 / 比赛圈数
- `PitWindowPressure` =
`TyreLife × RaceProgress`

交叉分类


- `Race_Year` (赛道×年份)
- `Compound_Stint` (轮胎×Stint)
- `Driver_Race` (车手×赛道)
- `Race_Compound` (赛道×轮胎)
- `RacePhase_TyreLifeBin`

统计特征

- 频率编码: `count / freq`
- 分组统计: `mean / std / diff`
- 数字签名: 提取数值的各位数字
- 精度特征: 四舍五入后转字符串


关键技术突破

1. 数据增强



合成数据有噪声，加入真实 F1 数据提升泛化

2. Rank Blend 锚点微调



不替换数值，只微调排名顺序

⚡ GPU 加速: CatBoost 训练

训练配置

```
params = dict(  
    iterations=8140,  
    learning_rate=0.018,  
    depth=8,  
    l2_leaf_reg=8.5,  
    bootstrap_type="Bayesian",  
    bagging_temperature=0.45,  
    auto_class_weights="Balanced",  
    task_type="GPU", # T4 GPU  
)
```

- 2 个随机种子集成
- 无验证集，全量训练
- 8140 轮迭代

为什么 CatBoost?

-  原生分类特征支持 — 不需要 one-hot 编码
-  GPU 加速 — 8000+ 轮只需 ~20 分钟
-  **Ordered Boosting** — 减少过拟合
-  **Balanced Weights** — 自动处理类别不平衡

XGBoost vs LightGBM vs CatBoost

	特征工程	GPU	分类特征	最终排名
LightGBM	需要编码		部分支持	1975
XGBoost	需要编码		需转 int	1359
CatBoost	不需要		原生	307



Claude Code 辅助开发

最终成绩

 排名 321 / 3023
AUC: **0.95453**

起点

2058 名 AUC 0.94068

中间

1006 名 AUC 0.94984

最终

321 名  AUC 0.95453

关键收获

技术层面

1. 特征工程 > 模型选择 > 超参调优
 - 15 → 300+ 特征带来最大提升
2. 数据质量很重要
 - 合成数据 + 真实数据混合训练
3. 集成学习的正确姿势
 - 不是简单平均，而是排名空间融合
4. **GPU** 是刚需
 - 8000+ 轮训练在 CPU 上不可想象

方法论

1. 快速迭代，持续提交
 - 每次小改进都提交验证
2. 从简单开始，逐步复杂
 - 先跑通基线，再加特征
3. 参考优秀方案
 - 竞赛社区的知识共享
4. **AI 辅助** ≠ 自动化
 - 方向判断仍需人来决策

Thank You

Kaggle Playground Series S6E5

Rank: 321 / 3023 | AUC: 0.95453

[Competition Link](#) · [Notebook](#)

Powered by  Slidev